J'ai choisi un jeu de données sur un parc de 4 éoliennes en open data. Ce jeu de données se nomme: "La haute borne" (https://opendata-renewables.engie.com/explore/dataset/data\_description/table/?q=kw&dataChart=eyJxdWVyaWVzljpbeyJjb25maWciOnsiZGF0YXNIdCl6ImRhdGFfZGVzY3Jrdu nom du parc éolien, situé dans la Meuse. L'analyse debute au 31 decembre 2016 et se termine au 12 janvier 2018.

```
In [1]: import pandas as pd
import time
import datetime
import matplotlib.pyplot as plt

In [2]: pwd()
Out[2]: '/home/administrateur'

In [3]: df = pd.read_csv('./STA002-2019/data/la-haute-borne-data-2017-2020.csv', sep=',')
In [4]: df.shape
Out[4]: (217588, 138)
```

Le data frame comporte 138 colonnes et 217588 lignes, nous allons donc selectionner que les colonnes nous interessant pour tracer la courbe de puissance d'une eolienne

- \* Date
- \* Nom eolienne
- \* vitesse vent
- \* puissance active (kwt)

#### Les colonnes sélectionnées sont:

```
• 'Wind_turbine_name',
```

- 'Date\_time',
- 'P\_avg',
- 'Ws1\_avg',
- 'Ws2\_avg','Ws\_avg',

```
In [6]: df1 = df.loc[:,['Wind_turbine_name','Date_time','P_avg','Ws1_avg','Ws2_avg','Ws_avg']]
In [7]: df1.shape
Out[7]: (217588, 6)
```

#### Traitement des valeurs NA

Y a t-il des valeurs NA? Remplacons les valeurs NA par 0

## Le data frame ne comporte plus que 6 colonnes, nous creeons les colonnes Date, Hour et Minute


```
df1['Date_time'] = pd.to_datetime(df1['Date_time'])
df1['Date']=df1['Date_time'].dt.date
            dfl['Date']=pd.to_datetime(dfl['Date'])
dfl['Time']=dfl['Date_time'].dt.time
dfl['Hour']=dfl['Date_time'].dt.hour
            df1['minute']=df1['Date_time'].dt.minute
            df1['Wind_turbine_name']=df1['Wind_turbine_name'].astype('category')
In [12]: dfl.dtypes
Out[12]: Wind_turbine_name Date_time
                                        category
datetime64[ns]
            P_avg
                                                 float64
            Ws1_avg
Ws2_avg
Ws_avg
                                                 float64
                                                 float64
                                                 float64
            Date
                                        datetime64[ns]
                                                  object
int64
            Time
            Hour
            minute
                                                    int64
            dtype: object
In [13]: df1.head()
Out[13]:
                Wind turbine name
                                            Date time
                                                           P_avg Ws1_avg Ws2_avg Ws_avg
                                                                                                     Date
                                                                                                              Time Hour minute
             0
                           R80711 2017-01-26 10:30:00 340.320010
                                                                       5.54
                                                                                 6.14
                                                                                          5.84 2017-01-26 10:30:00
                                                                                                                       10
                                                                                                                               30
                           R80711 2017-02-21 13:00:00 790.669980
                                                                       7.97
                                                                                 7.56
                                                                                          7.76 2017-02-21 13:00:00
                                                                                                                       13
                                                                                                                                0
             2
                           R80711 2017-02-07 23:40:00 41.389999
                                                                       3 97
                                                                                 4 07
                                                                                          4.02 2017-02-07 23:40:00
                                                                                                                       23
                                                                                                                               40
                           R80711 2017-02-08 00:40:00 -0.200000
             3
                                                                       2.69
                                                                                                                               40
                                                                                 3.00
                                                                                          2.84 2017-02-08 00:40:00
                                                                                                                       0
                           R80711 2017-02-21 18:50:00 522.719970
                                                                       7.04
                                                                                 6.59
                                                                                          6.82 2017-02-21 18:50:00
                                                                                                                       18
                                                                                                                               50
In [14]: dfl.shape
Out[14]: (217588, 10)
```

### La methode min et max sur la series Date\_time permet d'identifier l'intervalle de temps.


```
In [15]: df1.Date_time.min()
Out[15]: Timestamp('2016-12-31 23:00:00')
In [16]: df1.Date_time.max()
Out[16]: Timestamp('2018-01-12 23:00:00')
```

## Contrôle de l'intervalle de temps

### Debut de l'intervalle



### Fin de l'intervalle



### Il n'y a pas de ligne vide

```
In [19]: df1= df1.dropna(how='all', axis =0)
In [20]: df1.shape
Out[20]: (217588, 10)
```

Traitement des doublons. Y-a-t-il des doublons dans le dataset de la Haute Borne?

	_counts().loc[lambda		e_name','	P_avg',	'Ws_avg',	'Ws1_avg',	'Ws2_avg'])['Wind_	turbine_name'].va
]:	Date_time 2017-06-09 22:30:00	Wind_turbine_name R80721	P_avg 0.0	Ws_avg	Ws1_avg 0.0	Ws2_avg 0.0	Wind_turbine_name R80721	2
	2017-06-10 14:40:00	R80721	0.0	0.0	0.0	0.0	R80721	2
	2017-06-10 16:00:00	R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
2	2017-06-10 16:10:00	R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 16:20:00	R80711	0.0	0.0	0.0	0.0	R80711	2
		R80721	0.0	0.0	0.0	0.0	R80721	2
2	2017-06-10 16:30:00	R80711	0.0	0.0	0.0	0.0	R80711	2
		R80721	0.0	0.0	0.0	0.0	R80721	2
	2017-06-10 16:40:00	R80711	0.0	0.0	0.0	0.0	R80711	2
		R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 16:50:00	R80711	0.0	0.0	0.0	0.0	R80711	2
		R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 17:00:00	R80711	0.0	0.0	0.0	0.0	R80711	2
	2 2 2 2 3 2 3 3 3 3 3 3 3 3 3 3 3 3 3 3	R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 17:10:00	R80721	0.0	0.0	0.0	0.0	R80721	2
	2017 00 10 17.10.00	R80736	0.0	0.0	0.0	0.0	R80736	2
2	2017-06-10 17:20:00	R80711	0.0	0.0	0.0	0.0	R80711	2
	2017-00-10 17:20:00	R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 17:30:00	R80711	0.0	0.0	0.0	0.0	R80711	2
	2017-00-10 17.50.00	R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 17:40:00	R80711	0.0	0.0	0.0	0.0	R80711	2
	2017-00-10 17.40.00	R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 18:20:00	R80711	0.0	0.0	0.0	0.0	R80711	2
		R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 18:30:00	R80711	0.0	0.0	0.0	0.0	R80711	2
		R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 18:40:00	R80711	0.0	0.0	0.0	0.0	R80711	2
	2017 00 10 10140100	R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 18:50:00	R80711	0.0	0.0	0.0	0.0	R80711	2
	201. 00 10 10.30.00	R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 19:00:00	R80711	0.0	0.0	0.0	0.0	R80711	2
	2017 00-10 15.00.00	R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 19:10:00	R80711	0.0	0.0	0.0	0.0	R80711	2
	2017-00-10 19.10:00	R80721	0.0	0.0	0.0	0.0	R80721	2
				0.0	0.0	0.0		2
	2017 06 10 10 20 00	R80736	0.0				R80736	
	2017-06-10 19:20:00	R80711	0.0	0.0	0.0	0.0	R80711	2 2
		R80721	0.0	0.0	0.0	0.0	R80721	2
	2017 06 10 10 20 00	R80736	0.0	0.0	0.0	0.0	R80736	
	2017-06-10 19:30:00	R80711	0.0	0.0	0.0	0.0	R80711	2
		R80721	0.0	0.0	0.0	0.0	R80721	2
	2017 06 10 10 10 1	R80736	0.0	0.0	0.0	0.0	R80736	2
	2017-06-10 19:40:00	R80711	0.0	0.0	0.0	0.0	R80711	2
		R80721	0.0	0.0	0.0	0.0	R80721	2
		R80736	0.0	0.0	0.0	0.0	R80736	2
		R80711	0.0	0.0	0.0	0.0	R80711	2
	2017-06-10 19:50:00						D00701	
	2017-06-10 19:50:00	R80721 R80736	0.0	0.0	0.0 0.0	0.0 0.0	R80721 R80736	2 2

## Supprimons les doublons

```
In [22]: df2=df1.drop_duplicates()
In [23]: str(df1.shape[0]-df2.shape[0])+" lignes en double ont été supprimées"
Out[23]: '69 lignes en double ont été supprimées'
```

# Y a t il encore des lignes en double?

# => II n y a donc plus de doublon

Les eoliennes suivantes ont ete identifées dans le data set:

Pourquoi l'eolienne R80790 n'a t'elle pas le meme nombre d'observations que les eoliennes R80711, R80736, R80721? Nous allons essayer d'identifier l'ecart.

La fonction ci dessous, nous permet d'analyser le data frame pour 1 eolienne par Date:

```
In [26]: def turbine(i):
                df3 = (df2.loc[(df2['Wind_turbine_name'] == i)])
               df3 = df3.loc[:,['Date']]
df3=df3['Date'].value_counts(sort=True).head(15)
                return (df3)
In [27]: turbine('R80721')
Out[27]: 2017-06-10
          2017-06-09
2017-03-26
                           150
           2017-05-26
                           144
           2017-09-29
                           144
           2017-11-20
                           144
           2017-04-19
                           144
           2017-11-07
          2017 - 04 - 06
2017 - 10 - 25
                           144
                           144
           2017-03-24
                           144
           2017-10-12
                           144
           2017-03-11
                           144
           2017-02-26
                           144
           2017-12-03
                           144
           Name: Date, dtype: int64
```

# Que s'est il passé le 10/06/2017 ?

On définit une fonction pour avoir une vision par jour et par heure

```
In [28]: def jour(i,j):
    df_date=df2.loc[:,['Wind_turbine_name','Date','Time','Hour']]
    df_date = df_date.loc[(df_date['Date'] == i)&(df_date['Hour']==j)]
    df_date = df_date.groupby(['Date','Wind_turbine_name','Time']).count()
    return(df_date)
```

87424

175977

190582

87425

175978

R80721 2017-06-10 00:50:00

R80721 2017-06-10 00:50:00

R80721 2017-06-10 01:00:00

R80721 2017-06-10 01:00:00

R80721 2017-06-10 01:10:00

0.0

0.0

0.0

0.0

0.0

0.00

2.74

2.92

0.00

2.75

2.75

2.94

0.00

2.77

0.00 2017-06-10 00:50:00

2.74 2017-06-10 00:50:00

2.93 2017-06-10 01:00:00

0.00 2017-06-10 01:00:00

2.76 2017-06-10 01:10:00

50

50

0

0

10

```
In [29]: jour('2017-06-10',13)
Out[29]:
                                                   Hour
                 Date Wind turbine name
                                             Time
            2017-06-10
                                  R80711 13:00:00
                                                      2
                                          13:10:00
                                          13:20:00
                                                      2
                                          13:30:00
                                                      2
                                          13:40:00
                                                      2
                                          13:50:00
                                                      2
                                  R80721 13:00:00
                                                      2
                                          13:10:00
                                          13:20:00
                                          13:30:00
                                          13:40:00
                                          13:50:00
                                  R80736 13:00:00
                                          13:10:00
                                                      2
                                          13:20:00
                                                      2
                                          13:30:00
                                                      2
                                          13:40:00
                                          13:50:00
                                                      2
                                  R80790 13:00:00
                                          13:10:00
                                          13:20:00
                                          13:30:00
                                          13:40:00
                                          13:50:00
In [30]: df_analyse = df2.loc[(df2['Date']=='2017-06-10 00:00:00')&(df2['Wind_turbine_name']=='R80721')]
           df_analyse.sort_values(by='Time').head(15)
Out[30]:
                    Wind_turbine_name
                                               Date_time P_avg Ws1_avg Ws2_avg Ws_avg
                                                                                                 Date
                                                                                                         Time Hour minute
             87423
                               R80721 2017-06-10 00:00:00
                                                            0.0
                                                                    0.00
                                                                              0.00
                                                                                      0.00 2017-06-10 00:00:00
            175975
                               R80721 2017-06-10 00:00:00
                                                           0.0
                                                                    2.65
                                                                              2.45
                                                                                      2.55 2017-06-10 00:00:00
                                                                                                                  0
                                                                                                                          0
             85716
                               R80721 2017-06-10 00:10:00
                                                           0.0
                                                                    0.00
                                                                              0.00
                                                                                      0.00 2017-06-10 00:10:00
                                                                                                                  0
                                                                                                                         10
             48563
                               R80721 2017-06-10 00:10:00
                                                           0.0
                                                                    2.88
                                                                              2.62
                                                                                      2.75 2017-06-10 00:10:00
                                                                                                                  0
                                                                                                                         10
                               R80721 2017-06-10 00:20:00
             85717
                                                           0.0
                                                                    0.00
                                                                              0.00
                                                                                      0.00 2017-06-10 00:20:00
                                                                                                                  0
                                                                                                                         20
                               R80721 2017-06-10 00:20:00
            175976
                                                           0.0
                                                                    3.07
                                                                              2.85
                                                                                      2.96 2017-06-10 00:20:00
                                                                                                                  0
                                                                                                                         20
             85718
                               R80721 2017-06-10 00:30:00
                                                                                      0.00 2017-06-10 00:30:00
                                                           0.0
                                                                    0.00
                                                                              0.00
                                                                                                                  0
                                                                                                                         30
             48564
                                                                             2.43
                                                                                      2.46 2017-06-10 00:30:00
                               R80721 2017-06-10 00:30:00
                                                           0.0
                                                                    2.48
                                                                                                                  0
                                                                                                                         30
             48565
                               R80721 2017-06-10 00:40:00
                                                            0.0
                                                                    2.57
                                                                                      2.59 2017-06-10 00:40:00
                                                                              2.60
                                                                                                                  0
                                                                                                                         40
             85719
                               R80721 2017-06-10 00:40:00
                                                                              0.00
                                                                                      0.00 2017-06-10 00:40:00
                                                                    0.00
                                                                                                                         40
```

Constat pour le 10/06/2017 et pour l'eolienne R80721: Il y a eu 2 prises de mesures par les anemometres à la meme heure, 1 observation est correcte, 1 observation affiche des mesures nulles, pour P\_avg et Ws\_avg.

```
* On va supprimer ces observations qui fausseront notre analyse graphique
```

#### Moyenne du vent sur le parc eolien de la haute borne

Pour la representation graphique nous effectuerons le nuage de points de la puissance d'une eolienne. Pour valider ce graphique, et pour une bonne comprehension des données, <u>le tutoriel métier suivant a été suivi</u> (https://eolienne.f4jr.org/eolienne\_etude\_theorique).

- Variable name : P, variable long name: active power, unit : kw
- variable name: ws, variable long name: wind speed, unit: m/s

# Une fonction nous permettera d'afficher le graphique de l'eolienne sélectionnée


```
In [37]: def graphique(i):
    df4 = (df2.loc[(df2['Wind_turbine_name'] == i)])
    plt.scatter(df4['Ws_avg'],df4['P_avg'],c = 'steelblue', marker ='*', s=10)
    plt.title('Puissance de sortie de l\'éolienne' + str(i))
    plt.ylabel('Puissance electrique en kw')
    plt.xlabel('Vitesse moyenne du vent en m/s')
    plt.show()
In [38]: graphique('R80721')
```

Puissance de sortie de l'éolienneR80721

### La methode subplot nous permet d'afficher les 4 éoliennes dans le meme graphique

```
In [39]: a=df2.loc[(df2['Wind_turbine_name'] =='R80721')]['Ws_avg']
b=df2.loc[(df2['Wind_turbine_name'] =='R80721')]['P_avg']
c=df2.loc[(df2['Wind_turbine_name'] =='R80790')]['Ws_avg']
d=df2.loc[(df2['Wind_turbine_name'] =='R80790')]['Ws_avg']
e=df2.loc[(df2['Wind_turbine_name'] =='R80736')]['Ws_avg']
f=df2.loc[(df2['Wind_turbine_name'] =='R80736')]['P_avg']
g=df2.loc[(df2['Wind_turbine_name'] =='R80731')]['P_avg']
h=df2.loc[(df2['Wind_turbine_name'] =='R80711')]['P_avg']
In [40]: fig, (ax1, ax2,ax3,ax4) = plt.subplots(nrows=4, ncols=1, figsize=(15, 10))
plt.suptitle('Nuage de points puissance de sortie des éoliennes', fontsize=16)
ax1.scatter(g, h, s=5, c='time', marker=">")
ax1.scatter(g, h, s=5, c='steelblue', marker=">")
ax2.scatter(a, b, s=5, c='steelblue', marker=">")
ax3.scatter(c, d, s=5, c='darkblue', marker=">")
ax3.scatter(c, d, s=5, c='darkblue', marker=">")
ax4.scatter(e, f, s=5, c='purple', marker=">")
ax5.scatter(e, f, s=5, c='purple', marker=">")
ax4.scatter(e, f, s=5, c='purple', marker=">")
ax5.scatter(e, f, s=5, c
```

### Nuage de points puissance de sortie des éoliennes



## En reprenant le wiki éolienne et avec la lecture des differents graphiques:

- Juqu à la vitessse de démarrage environ 4 m/s soit 14 km/h : puissance de sortie nulle
- vitesse nominale environ 12 m/s soit 43,2 km/h
- Coupure des éoliennes environ 20 m/s soit 72 km/h: puissance de sortie nulle pour protection des éoliennes